창의적 SW프로그램 경진대회 - 빅데이터 분석 부문

데이터 분석 계획서

소통 부족으로 인한 세대 갈등 완화 프로그램 제안

Team 고양이

명지대학교
MYONGJI UNIVERSITY

목차

CONTENTS

1

분석 배경



2

분석 절차



3

분석 계획



4

일정 계획



분석 배경

심화하는 세대 갈등과 도서관 이용률 감소



대한민국은 급속한 산업화와 민주화 과정을 거치며 짧은 시간에 큰 사회 변화를 경험했다.
이에 따라 세대 간 경험과 가치관의 차이가 벌어졌고,
빠른 변화 속 소통의 기회가 부족해 세대 간 갈등이 심화하였다.

공감 능력을 향상하는 독서는, 소통 부족으로 인한 세대 갈등을 완화하는 데
중요한 역할을 할 것으로 예상한다.
그러나 현재 미디어의 발달로 성인 독서량과 도서관 이용률이 급격히 감소하고 있다.
데이터 분석을 통해 소통 부족과 세대 갈등의 연관성을 규명할 필요가 있으며,
갈등을 해소할 방안을 촉구해야 한다.

따라서 독서를 통한 세대 갈등 완화 프로그램 제안은 미디어 시대에 낮아진 도서관 이용률과 심화한 세대 갈등을 해소할 수 있는 효과적인 방안이 될 것으로 기대하며, 이에 대한 데이터 분석을 진행하고자 한다.

분석 계획

분석 목표 및 방향

분석 목표

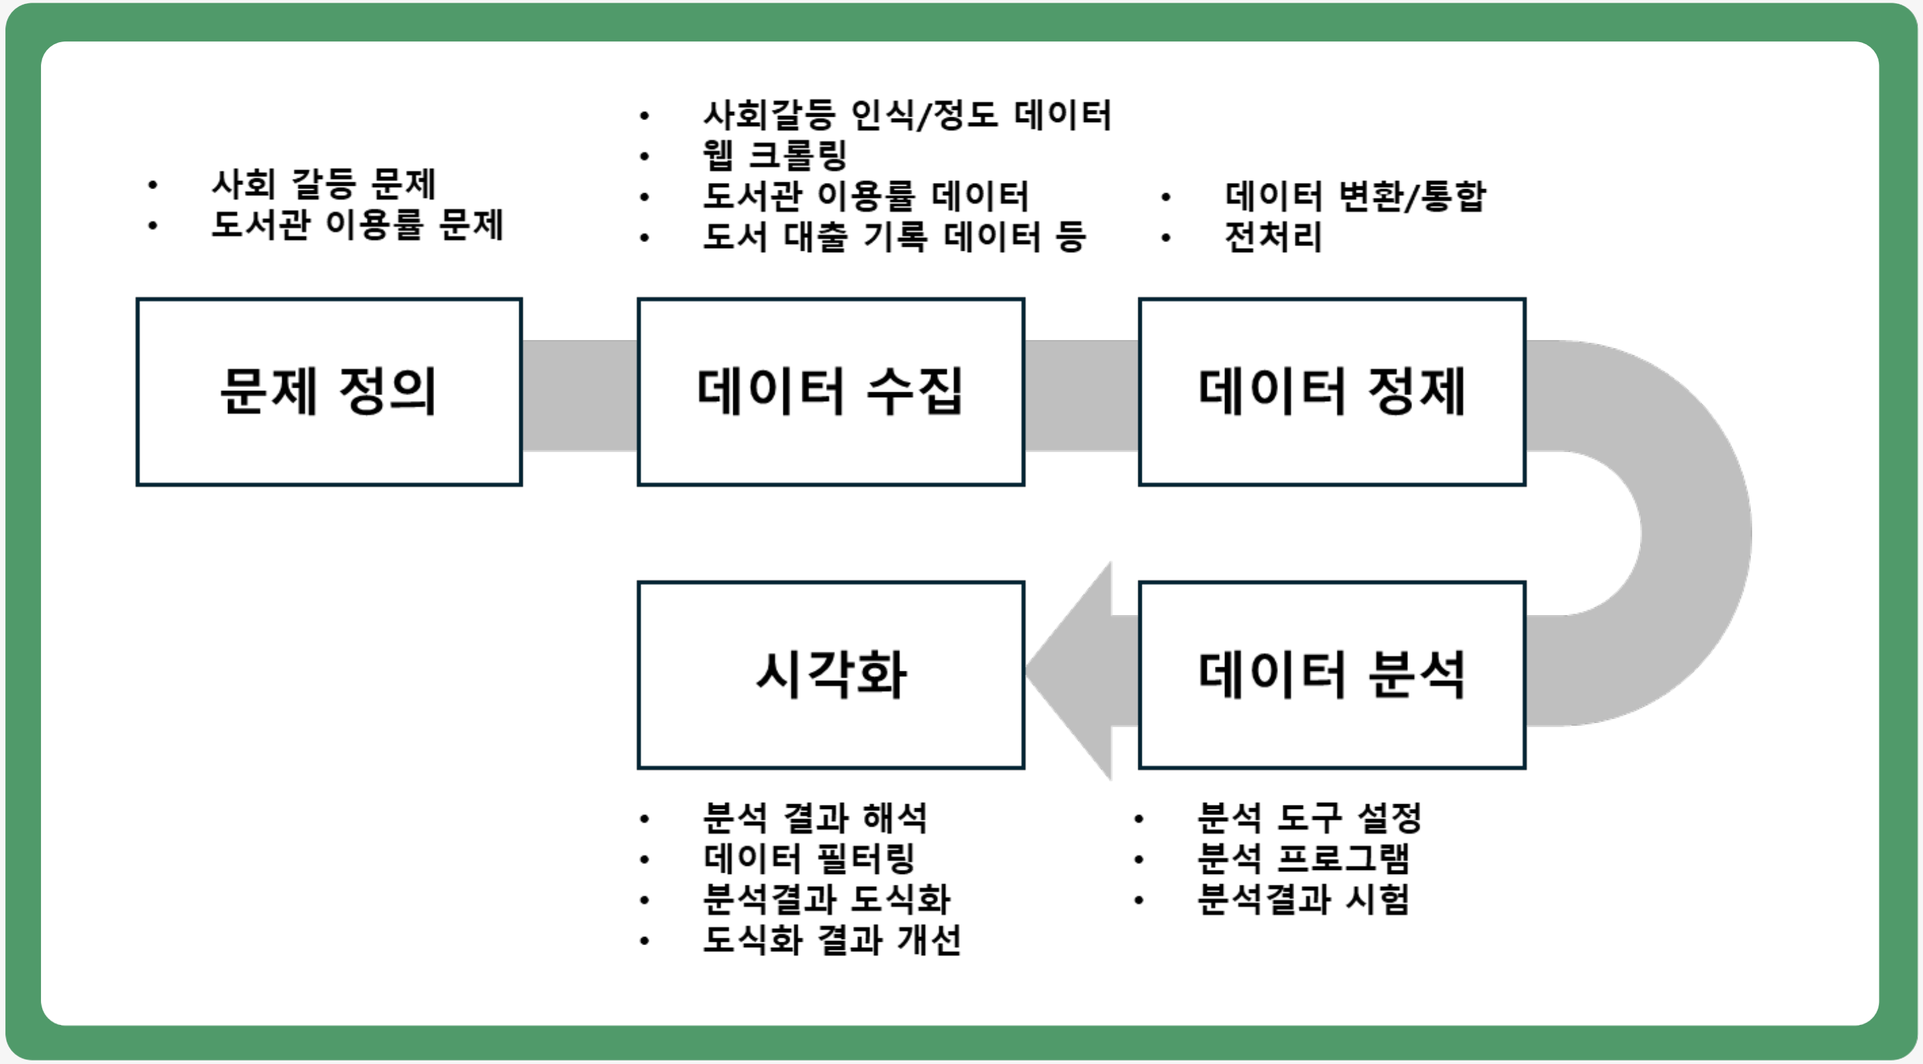
먼저 여러 데이터 분석을 통해, 현재 세대 갈등과 도서관 이용률, 저조한 독서량을 인식함.
이후 도서관 대출 데이터를 이용하여, 연령대별로 많이 읽는 도서의 토픽 추출
추출된 토픽을 세대 간 소통의 연결고리로 삼음.
이를 이용해 세대 간 소통 부족과 낮은 독서율 문제를 해결하기 위한 도서관 프로그램 제안

분석 방향

여러 사이트를 통해 다양한 데이터를 수집
분석에 필요한 데이터를 목표에 맞게 정제하고 변환하는 전처리 과정 진행
적절한 분석 도구를 설정하고 프로그램을 통해 데이터 분석
분석 결과를 해석하고 데이터를 필터링하여 도식화

분석 절차

데이터 분석 로드맵



분석 계획

국민의 세대 갈등 인식 관찰

항목	항목의 세부 내용	비고
수집 방법	한국행정연구원 2023 사회통합보고서의 세대 갈등 인식 표 데이터를 엑셀로 가져와 csv 형태로 가공함. 공식 통계 결과인 사회통합 보고서에서 세대 갈등을 충분히 인식하고 있다는 결과가 드러날 시, 데이터 분석 주제 확정	수집 난이도 : 하
분석 방법	1) CSV 형식으로 저장된 세대갈등 인식 통계정보를 가공하여 성별, 소득 분위, 학력 등의 불필요한 행을 삭제하고 19~39세, 65세 이상의 데이터만 남긴다. 2) 19~29세와 29세~39세 행은 평균을 구하여 '청년'이라는 새 행을 만든다. 3) '청년' 행과 '65세 이상' 행의 평균을 구해 청년+노년층의 평균적 인식을 드러내는 데이터프레임으로 최종 가공한다.	분석 도구 : 파이썬 pandas
분석 목표	세대 갈등 인식 데이터를 분석한 뒤 시각화하여, 국민들이 현 시대의 세대갈등을 어떻게 인식하는지 관찰하는 것이 목표	시각화 방법 : 원형 그래프

분석 계획

세대갈등 인식 : 웹 크롤링

항목	항목의 세부 내용	비고
기획 및 목표	갈등이 드러나는 기사 댓글을 통해, 양 극단이 서로에 대해 어떤 갈등 표현을 분출하는지 양상을 파악함.	수집 난이도 : 중
수집 및 분석	[사용 모듈] selenium.webdriver: 웹과의 상호작용 자동화 time: 웹 크롤링 하는 동안 일정 대기 시간 생성 pandas: 데이터 분석 BeautifulSoup: HTML, XML 문서 파싱 [데이터 분석 방법] 1) webdriver.Chrome()와 deriver.get(url)을 사용하여 기사 URL로 이동해 모든 댓글이 로드될 때까지 과정을 반복한다. 1)의 과정에서 댓글 클릭 후 time 모듈을 이용해 만든 변수를 사용하여 잠시 대기하는 과정을 추가한다. 2) 모든 댓글이 로드되면 BeautifulSoup으로 데이터를 추출한다. 사용자 이름과 날짜, 댓글을 CSS 선택자를 사용해 추출하여 각각 다른 리스트에 저장하고 리스트들을 한 튜플에 모은다. 3) pandas를 이용해 새 데이터프레임을 생성하고, 엑셀 파일로 저장한다. 4) 추출된 데이터를 관찰하고, 세대 갈등이 잘 드러나는 댓글을 선택한다.	추출된 데이터를 관찰하고, 세대 갈등이 잘 드러나는 댓글을 선택

분석 계획

청년층, 노년층이 생각하는 세대 갈등의 원인

항목	항목의 세부 내용	비고
수집 방법	한국행정연구원 2023 사회통합보고서의 세대갈등 원인 1순위 표 데이터를 엑셀로 가져와 csv 형태로 변환	수집 난이도 : 하
분석 방법	1) CSV 형식으로 저장된 세대갈등 원인 통계정보를 가공하여 성별, 소득 분위, 학력 등의 불필요한 행을 삭제하고 19~39세, 65세 이상의 데이터만 남긴다. 2) 19~29세와 29세~39세 행은 평균을 구하여 '청년'이라는 새 행을 만든다. 3) '청년' 행과 '65세 이상' 행의 평균을 구해 청년+노년층의 평균적 인식을 드러내는 데이터프레임으로 최종 가공한다.	분석 도구 : 파이썬 pandas
분석 목표	청년층과 노년층이 세대 갈등의 원인의 1순위가 무엇이라고 생각하는지 한 눈에 들어오게 원형 그래프로 시각화	시각화 방법 : 원형 그래프 matplotlib

분석 계획

독서율 추이 데이터

항목	항목의 세부 내용	비고
수집 방법	문화샘터 통계 목록의 독서율 추이 표를 xlsx 형식으로 저장한다. 2002년~2013년은 종이책, 2013~2019년은 종이책+전자책, 2019년 이후는 종이책+전자책+오디오북의 데이터가 포함되어있으므로 각각 따로 저장해 가공해야 한다.	수집 난이도 : 하
분석 방법	1) 만화책, 잡지, 읽지 않음 등의 불필요한 열을 삭제하고, 필요한 연도 별 '읽음' 데이터만 남긴다. 2) 성별, 가구소득, 직업 등의 불필요한 행을 삭제하고, 성인 전체 데이터만 남긴다. 3) 인덱스, 칼럼명 등을 수정한 뒤, 정렬을 오름차순으로 한다. 4) 2002~2013, 2013~2019, 2019 데이터를 각각 수정하고, 열을 기준으로 2002~2021까지의 데이터 프레임을 합친다.	분석 도구 : 파이썬 pandas
분석 목표	2002 이후로 꾸준히 하락하고 있는 독서율을 드러내기 위해 꺾은선 그래프로 시각화	시각화 방법 : 꺾은선 그래프 matplotlib

분석 계획

연령대 별 도서관 이용률

항목	항복의 세부 내용	비고
수집 방법	문화샘터 통계 목록의 '도서관 이용률(성인)' 데이터를 CSV 형식으로 저장한다.	수집 난이도 : 하
분석 방법	1) 사례수, 비이용 등의 불필요한 열을 삭제하고, 연도 별로 '도서관 이용' 열만 남긴다. 2) 전체, 성별, 연간 독서량, 학력 등의 불필요한 행을 삭제하고, 연령 행만 남긴다. 3) 인덱스, 칼럼명 등을 수정한 뒤, 정렬을 오름차순으로 한다. 그 다음, 행과 열을 반전시킨다. 4) 결측치를 확인한 뒤, 이를 평균으로 대치한다.	분석 도구 : 파이썬 pandas
분석 목표	현재 연령대별 도서관 이용률 실태를 파악함.	시각화 방법 : 꺾은선 그래프 (인터랙티브 그래프) plotly

분석 계획

LDA 토픽 모델링 (1차)

항목	항목의 세부 내용	비고
수집 방법	도서관 정보나루 사이트에서 7월 달의 20대 및 30대, 60대 이상의 인기 대출 도서 데이터 1000권을 CSV 형식으로 저장한다.	수집 난이도 : 하
분석 방법	1) 수집한 데이터 '서명, 대출건수' 제외 나머지 열 제거 2) 서명 뒤의 부가 설명 부분 제거 3) 같은 제목을 가진, 시리즈물 중복 제거 4) 상위 500개 도서 추출 5) matplotlib를 활용하여, 연령층 별 상위 20개의 도서를 대출량이 높은 도서가 맨 위로 오도록 막대그래프로 시각화한다.	분석 도구 : 파이썬 pandas
분석 목표	각 연령별 상위 20개의 도서를 통해, 연령대 별로 어떤 도서를 주로 읽는지 한눈에 파악함.	시각화 방법 : 막대 그래프 matplotlib

분석 계획

LDA 토픽 모델링 (2차)

항목	항목의 세부 내용	비고
수집 방법	앞에서 수집했던 인기 대출 도서 데이터를 바탕으로, Beautifulsoup과 Selenium을 활용하여 도서 판매 사이트 YES24에서 책 소개 크롤링	수집 난이도 : 중
분석 방법	1. Konlpy Mecab 태그 중 길이가 2 이상인 '일반명사, 고유명사, 어근' 만 추출 2. 5회 이하로 등장하는 단어와 상위 50% 단어 필터링 3. Genism 활용, 주제 개수에 따른 Coherence score 확인 후 최종 토픽 개수 결정 4. 토픽의 단어들을 보며, 토픽의 이름을 붙임 4. 같은 방식으로 청년층, 노년층, 청년층+노년층 각각 진행 5. 분석 결과를 PyLDAvis를 이용해 시각화	분석 도구 : Konlpy Mecab Genism
분석 목표	도서별 책 소개 데이터를 크롤링하여 토픽별 핵심 단어를 시각화, 이후 토픽별 주요 단어를 워드클라우드로 시각화	시각화 방법 : PyLDAvis WordCloud

아이디어 기획 1) 독서를 통한 고민 해결 프로그램

항목	항목의 세부 내용	비고
기획 및 목표	세대 간 소통의 부재를 해결하고자, 독서를 통해 청년과 노년이 서로의 삶을 나눌 수 있는 공유 플랫폼을 제공한다. 청년은 노인의 지혜와 통찰을 통해 깊이 있는 사고를 배울 수 있고, 노인은 청년의 열정과 새로운 시각을 통해 삶의 활력을 얻을 수 있다. 이를 통해 세대 간 이해와 공감이 증진되며, 더 나아가 사회적 통합을 촉진하는 소통의 장의 효과를 얻는 것이 목표이다.	제작자의 수준에 벗어난 부분까지는 구현하지 않고, 구현 계획서로 대체
구현 계획	**[구현 기능 1 : 고민 공유]** 청년 고민 입력 -> 60대 이상이 많이 대출한 책&베스트셀러 중 입력한 고민의 장르 도서와 소감문 추천 노인 고민 입력 -> 청년이 많이 대출한 책 & 베스트셀러 중 입력한 고민의 장르 도서와 소감문 추천 (특정 고민의 장르 도서 추천 방법 : LDA 분석을 통해 여러 책 소개 문서에서 주제(토픽)를 추출한 후, 특정 토픽을 선택하여 해당 토픽이 주요하게 다루어진 문서들을 문서 할당 및 문서 필터링 과정을 통해 식별하고, 그 결과를 목록으로 불러와 사용자에게 제공한다.) **[구현 기능 2. 소감문 작성]** 소감문 작성 기능을 제작하여 각 세대는 자유롭게 읽은 책에 대해 소감문을 작성할 수 있도록 함. 소감문 작성 페이지에 소감문 주제 키워드를 선택하는 기능 추가 -> 작성된 소감문은 소감문 페이지에 기록되고, 소감문 주제 키워드에 따라 [구현 기능 1]에도 들어간다. **[구현 기능 3 : 세대 간 Q&A]** 질문자는 질문을 남기고 답변받고 싶은 세대(청년/노년/모두)를 선택할 수 있음 답변자는 본인의 세대를 입력하고 답변함 이로써 ***'청년-노년, 청년-청년, 노년-노년의 소통의 장'***을 만든다.	구현 도구 : HTML

일정 계획

데이터 분석 진행 일정 계획

	07월 1주차	07월 2주차	07월 3주차	07월 4주차	08월 1주차	08월 2주차	08월 3주차
Pending	주제 선정 계획 PPT 제작	세대 갈등 인식 관찰 웹 크롤링을 통해 세대 갈등 인식 세대 갈등의 원인 분석	독서율 추이 데이터 연령대별 도서관 이용률 분석	LDA 토픽 모델링 1차	LDA 토픽 모델링 2차	아이디어 제안	발표 PPT 제작
세부 계획	• 주제 아이디어 제시 • 아이디어에 대한 의견을 나눔 • 계획 PPT 제작	• 데이터 수집 • 데이터 전처리 • 데이터 시각화 • 웹 크롤링	• 데이터 수집 • 데이터 전처리 • LDA 사전 공부	• 데이터 수집 • 데이터 전처리 • 데이터 시각화	• 웹 크롤링 • 단어 추출 • 토픽 시각화	• 분석 데이터를 바탕으로 문제 해소를 위한 아이디어 제안	• 발표 PPT 제작

감사합니다

소통 부족으로 인한
세대 갈등 완화
프로그램 제안

창의적 SW프로그램
경진대회
데이터 분석 부문